

PhysFormer: 面向安全约束虚拟电厂预测的物理引导因果耦合受限残差 Transformer

作者一* *学院, 大学, 城市, 国家. 邮箱: xxx@uni.edu

Abstract—虚拟电厂 (VPP) 预测要求预测结果满足物理约束, 然而数据驱动的深度学习方法经常产生物理上不可能的输出, 例如负功率或夜间太阳能发电。事后裁剪可以抑制违规, 但会引入不可导的死区, 破坏端到端优化。本文提出 PhysFormer, 一种有界残差 Transformer, 通过三个集成组件结构上强制物理合规性。首先, 有界物理激活残差 (BPAR) 架构采用可导 Softplus 下界钳制结合物理活动掩码, 结构上防止负预测, 在保持连续梯度流的同时实现 BVR=0.00%。其次, 正交物理引导因果耦合 (PGCC) 模块通过监督正则化将物理先验印刻到潜层门控变量上, 产生强皮尔逊相关系数 ($r = 0.8306$), 在不牺牲预测容量的前提下赋予结构透明性。第三, 物理约束课程训练策略顺序引入物理约束以避免早期梯度冲突。在真实 3 年 VPP 数据集上的实验表明, PhysFormer 实现了优越的准确度-合规性帕累托定位, 在无约束基线的 6% MSE 范围内, 同时在标准和极端天气条件下保持零边界违规。

Index Terms—物理信息机器学习, 虚拟电厂 (VPPs), Transformer 架构, 因果可解释性, 物理合规性, 分布式能源预测。

符号表

$P_{\text{net}}, P_{\text{load}}, P_{\text{pv}}, P_{\text{wind}}$	净负荷、负荷、光伏和风电功率 [MW]。
G, T, v	辐照度 [W/m ²]、温度 [°C]、风速 [m/s]。
$\eta_{\text{pv}}, \beta_T$	光伏转换效率和温度系数 [°C]。
$v_{\text{ci}}, v_r, v_{\text{co}}$	切入、额定和切出风速 [m/s]。
Γ_{run}	风机运行指示函数。
$P_{\text{base}}, T_c, \gamma$	基准负荷 [MW]、舒适温度 [°C]、灵敏度。
$a_{\text{pv}}, a_{\text{wind}}$	物理激活掩码 $\in [0, 1]$ 。
$p_{\text{pv}}, p_{\text{wind}}$	门控硬先验。
$g_{\text{pv}}, g_{\text{wind}}$	PGCC 门控 ($g_{\text{pv}} \in [0, 1.5]$)。
α, v	课程学习参数和天气波动率。
$\mathcal{L}_{\text{total}}, \mathcal{L}_{\text{mse}}, \mathcal{L}_{\text{net}}$	混合损失、MSE 损失和净负荷损失。
$\mathcal{L}_{\text{bvr}}, \mathcal{L}_{\text{rvr}}, \mathcal{L}_{\text{prior}}$	安全性和正则化损失。
γ_{ema}	动态损失平衡比例。
S, P, D	序列长度 (672, 96)、模型维度 (512)。
BVR, MVS, RVM	安全性和爬坡违规指标。
PGCC, NRMSE, BPAR	门控、误差和残差机制。

I. 引言

A. 背景与动机

可再生能源并入电网推动了虚拟电厂 (VPPs) 的发展, 以聚合和管理分布式能源资源。对 VPP 动态——特别是电力负荷、光伏 (PV) 发电和风力发电——的准确预测对于电网稳定性、经济调度和运行风险管理至关重要 [1]–[5]。

与单变量预测不同, 协作式 VPP 管理需要跨这些相互关联的领域进行同步、协调的预测, 且必须严格遵守每种能源形式的物理约束。例如, 光伏发电本质上受太阳辐射约束, 在夜间无法发电, 而风力发电则依赖于局部风速驱动的非线性风机功率曲线。

其早期预测方法多依赖于统计外推, 而随着分布式能源的增加, Transformer 架构凭借其捕获长程时间动态的能力, 已成为该领域的主流范式 [6]–[9]。然而, 可靠的调度决策不仅取决于最小化原始统计预测误差, 还取决于预测模型是否从根本上遵守支配电力系统的物理定律。

B. 现有数据驱动方法的局限性

尽管深度学习在时间序列预测中取得了进展, 但其在 VPP 调度中仍面临三大核心挑战 [10], [11]:

1) **纯数据驱动的物理越界**: 虽然神经网络在最小化统计误差方面表现出色, 但其作为“黑盒”运行, 忽视了物理原理。这导致模型经常产生物理上不可能的预测, 如夜间非零太阳能或负值风电, 严重损害了运行安全性和操作员信任。

2) **物理信息增强 (PINN) 在随机环境下的僵化**: 传统的 PINN [12] 多将物理方程作为损失函数中的软约束。然而, VPP 运行在高度随机的环境中, 固定参数的软约束难以动态适应多变的气象分布, 且容易受到数据驱动项与物理惩罚项之间的梯度冲突影响, 导致收敛困难 [13], [14]。

3) **结构性追溯缺失**: 现有模型缺乏因果可解释性。依赖事后归因或注意力可视化无法提供确定性的物理因果归因 [15]。电网操作员需要模型显式展示可测量环境变量 (如辐照度) 如何支配设备激活边界, 而目前在动态关联网络激活与物理状态转换方面仍存在技术缺口 [16], [17]。

C. 所提方法与主要贡献

为此, 本文提出了 **PhysFormer**, 一种物理引导的因果 Transformer, 通过将可微物理先验内生化的神经网络锚定在内在的结构合规性上。其主要贡献如下:

1) **** 受限物理动作残差 (BPAR) 架构 ****: 通过引入 Softplus 歧义消除与物理激活掩码, PhysFormer 确保预测轨迹在数学上驻留在绝对安全的流形上。该机制在不使用非连续性事后剪裁的情况下, 将边界违规率 (BVR) 降至绝对 0.00%, 且能将边界处的结构性修正控制在物理可忽略的量级。

2) **** 正交物理引导因果耦合 (PGCC) 机制 ****: 通过显式正则化对潜层门控进行物理对齐, 实现了皮尔逊相关系数 $r = 0.8306$ 的确定性物理关联。消融实验证实, 这种透明性的获得与精度目标是正交的 (即不牺牲 MSE 精度), 同时使模型对 50% 幅度的外源传感器噪声具备极强的韧性。

II. 所提 PhysFormer 框架

A. 数学形式化与预测任务构建

在虚拟电厂 (VPP) 预测的背景下, 目标是预测三个不同子组件的未来功率输出: 基准负荷 (P_{load})、光伏发电 (P_{pv}) 和风力发电 (P_{wind})。VPP 的总净功率需求定义为 $P_{\text{net}} = P_{\text{load}} - P_{\text{pv}} - P_{\text{wind}}$ 。令 $\mathcal{X}_{\text{stat}} \in \mathbb{R}^{B \times S \times 3}$ 表示三个组件在长度为 S 的历史回顾窗口内的历史观测序列, 其中 B 是批大小 (batch size)。同时, 相应的历史天气条件——包括温度、辐照度和风速——由 $\mathcal{X}_{\text{weather_hist}} \in \mathbb{R}^{B \times S \times 3}$ 表示。模型还获得了预测时界 P 内的未来天气预报, 记为 $\mathcal{X}_{\text{weather_future}} \in \mathbb{R}^{B \times P \times 3}$ 。给定这些输入, 预测模型旨在生成输出 $Y \in \mathbb{R}^{B \times P \times 3}$ 的点预测, 提供负荷、光伏和风电组件各自的未来轨迹。

B. 整体架构




Fig. 1. 所提出的 PhysFormer 的整体架构。它具有双流设计: 由 Transformer 编码的统计流和显式物理映射流。这些流通过物理引导的因果耦合 (PGCC) 模块进行因果融合。未来天气条件使用门控线性单元 (GLU) 注入, 以提供显式的远见。最后, 理论锚定的残差头在物理导出的激活门控约束下对预测进行微调, 消除了非物理预测。

PhysFormer 被构建为一个具有物理引导因果耦合 (PGCC) 和理论锚定激活门控机制的双流 Transformer。处理流程严格遵循七步数据流: (1) 将历史观测值 $\mathcal{X}_{\text{stat}}$ 和天气 $\mathcal{X}_{\text{weather_hist}}$ 连接并由维度为 $d_{\text{model}} = 512$ 、前馈维度 $d_{\text{ff}} = 1024$ 、8 个头和 3 层的 Transformer 编码器进行编码, 产生统计特征表示。(2) 同时, $\mathcal{X}_{\text{weather_hist}}$ 通过显式物理映射 (ExplicitPhysicalMapping) 模块处理, 生成物理历史特征和理论基准。(3) PGCC 模块将统计序列与物理表示融合, 形成因果耦合的潜在状态, 并计算物理对齐正则化损失。(4) FlattenHead 机制将序列从历史维度 S 线性投影到未来预测时界 P 。(5) 为了提供显式的远见, 未来天气变量 $\mathcal{X}_{\text{weather_future}}$ 被映射到物理表示, 并通过具有残差逻辑的门控线性单元 (GLU) 注入到潜在序列中。(6) 共享投影层将特征路由到不同的输出头——按深度区分——以预测每个组件的残差修正。(7) 理论锚定

输出结构应用物理导出的激活掩码, 动态抑制或释放神经残差修正, 产生最终的 VPP 预测。

C. 显式物理映射

物理注入的核心在于显式物理映射 (ExplicitPhysicalMapping) 层, 它通过领域特定的方程将相关的天气变量映射到理论功率基准。

1) 光伏模型: 理论光伏发电由辐照度 G 驱动, 并受电池温度影响而退化, 建模为:

$$P_{\text{pv}} = G \cdot \eta_{\text{pv}} \cdot \text{clamp}(1 - \beta_T \cdot (T - 25), 0, 1.5) \quad (1)$$

其中 T 是温度, $\eta_{\text{pv}} = 0.33 \cdot \sigma(\theta_{\text{eff}})$ 是受单结硅电池 33% 的 Shockley-Queisser 极限约束的可学习转换效率, $\beta_T = \text{softplus}(\theta_{\text{temp_coef}}) \times 0.01 \in [0.003, 0.005] / ^\circ\text{C}$ 是温度系数。为了在梯度反向传播期间保持数值稳定性, 同时惩罚非物理的负效率, 温度相关的退化通过 1.5 的饱和限制约束在安全运行流形内, 这在容纳亚零环境下的效率增益的同时, 不会导致发散的梯度更新。

2) 风电模型: 风电极限在很大程度上取决于运行阈值: 切入风速 v_{ci} 、额定风速 v_r 和切出风速 v_{co} 。为了保持严格的阈值顺序, 我们利用累积增量结构, 其中 $v_{\text{ci}} = \text{softplus}(\theta_{\text{ci}})$, $v_r = v_{\text{ci}} + \text{softplus}(\theta_{r_delta})$, 以及 $v_{\text{co}} = v_r + \text{softplus}(\theta_{\text{co_delta}})$ 。功率输出使用经过运行合规性修改的理想化软曲线近似:

$$P_{\text{wind}} = \text{scale}_{\text{wind}} \cdot \sigma(5 \cdot (w_{\text{norm}} - 0.5)) \cdot I_{\text{running}} \quad (2)$$

其中 w_{norm} 是归一化风速, $\text{scale}_{\text{wind}}$ 是代表装机容量可学习幅度因子, 而 I_{running} 是一个概念性指示函数, 仅在 $[v_{\text{ci}}, v_{\text{co}}]$ 运行窗口内严格为 1, 否则为 0。必须指出的是, 虽然(2)利用 I_{running} 来定义理想的运行边界, 但将其直接嵌入神经网络会引发不可微的零梯度死区 (zero-gradient dead zone)。为了从根本上规避这一问题并维持连续的梯度流, PhysFormer 在实际的神经计算图中, 完全使用连续且完全可微的物理激活掩码 a_{wind} (其推导详见随后的第 II-C4 节) 替换了 I_{running} 。因此, 风电组件的实际前向传播路径被正式执行为:

$$P_{\text{wind,actual}} = \text{scale}_{\text{wind}} \cdot \sigma(5 \cdot (w_{\text{norm}} - 0.5)) \cdot a_{\text{wind}} \quad (3)$$

这种数学上的解耦无缝地连接了刚性的物理阈值与端到端的反向传播, 彻底避免了使用直通估计器 (Straight-Through Estimators, STE)。计算得出的 $P_{\text{wind,actual}}$ 随后直接作为 BPAR 机制中的 $P_{x,\text{theory}}$ 基准 (8), 而相同的可微掩码 a_{wind} 则被复用为抑制门控 a_x (9), 以确保对基准和神经残差的同步物理门控。此外, 累积增量优化确保在梯度更新期间重叠的边界永远不会导致参数状态崩溃, 使得约束在任何时候都在结构上得到保证。

3) 负荷模型: 我们通过二次热舒适模型抽象了由人类制冷和采暖活动触发的电力负荷变化:

$$P_{\text{load}} = P_{\text{base}} + \text{softplus}(\gamma) \cdot (T - T_c)^2 \quad (4)$$

其中 T_c 是一个可优化的热舒适基准, 初始值为 20°C 。虽然 Transformer 的内在自注意力机制从根本上擅长提取表征人类社会活动的刚性昼夜和周周期性, 但显式物理映射流刻意限制为隔离电力负荷的非线性、温度驱动的波动。因此, 我们通过该二次舒适模型概念化热诱导的方差, 显式地将气象敏感性与统计捕获的时间基准解耦。

4) 物理激活门控: 为了防止神经网络臆造出非物理的伪影, 我们提出了一种显式的激活门控方案。对于光伏, 夜间无关性建模为 $a_{\text{pv}} = \tanh(10 \cdot P_{\text{pv,theory}})$ 。对于风电,




Fig. 2. 收敛后学习到的显式物理映射函数。(a) 不同辐照水平下的光伏温度退化，由可学习系数 $\beta_T = 0.0041/^\circ\text{C}$ 支配。(b) 风力机功率曲线，在切入 ($v_{ci} = 3.5 \text{ m/s}$)、额定 ($v_r = 12.0 \text{ m/s}$) 和切出 ($v_{co} = 25.0 \text{ m/s}$) 阈值之间具有平滑的 S 形过渡。(c) 具有经数据校准的舒适温度 $T_c \approx 20^\circ\text{C}$ 的负荷热舒适需求。所有参数见表 III。

随风速变化的激活采用可微软限制进行参数化： $a_{\text{wind}} = \tanh(10 \cdot \text{softplus}(v - v_{ci}) \cdot \text{softplus}(v_{co} - v))$ 。虽然 a_{wind} 中的 softplus 算子乘积在理论上会在风速趋近 v_{co} 时诱发逐渐的衰减——从而略微偏离了刚性的水平额定输出平台——但这种保守的物理偏置已被无约束的神经残差头有效吸收。在 BPAR 框架内，残差机制会自动补偿由于数学平滑产生的二阶阻尼效应，确保最终输出在不牺牲可微性的情况下维持额定功率特性。风电组件极低的预测误差（表 V）证实了这种混合架构在调和连续梯度流与硬阈值行为方面的有效性。负荷本质上是刚性的，采用无条件乘法器 $a_{\text{load}} = 1$ 。这些物理导出的激活在最终的有界物理激活-残差（BPAR）层中充当确定性锚定的掩码，在确保连续梯度流的同时，无缝衔接有功运行状态与零发电周期之间的过渡。

D. 物理引导因果耦合 (PGCC)

物理引导因果耦合 (PGCC) 模块根据物理编码的表示协调从统计流中检索的知识。

1) 物理锚定的光照先验：我们首先建立一个数据无关的硬先验，以拒绝虚假相关性。门控依赖于参数化的照明 S 形先验 $p_{\text{pv}}^{\text{prior}} = \sigma(k_{\text{irr}} \cdot (G_{\text{norm}} - \theta_{\text{irr}}))$ ，约束动态保持为 $\theta_{\text{irr}} \in [-2.0, 0.5]$ ，斜率边界为 $k_{\text{irr}} \in [1, 100]$ 。这种硬先验在白昼和黑夜间隔之间建立了不容妥协的区别，拒绝了数据嵌入中的噪声伪影。

2) 波动感知软门控：为了动态衡量对网络的信任度，系统嵌入了提取为 $v = \frac{1}{C} \sum_c \text{Var}_t(\mathcal{X}_{\text{weather}, c})$ 的序列级样本波动。这些动态连同统计嵌入和注意力输出，被路由通过一个产生未缩放软条件图的下采样多层感知器。这种波动输入有助于网络动态调整其信任比，在条件不稳定时降低物理组件的权重。

3) 源异构门控边界：耦合实现了独立的激活范围，以适应发电来源的特性：

$$\text{gate}_{\text{pv}} = \text{smooth}(p_{\text{pv}}^{\text{prior}} \cdot (0.5 + g_{\text{soft_pv}})) \in [0, 1.5] \quad (5)$$

$$\text{gate}_{\text{load}} = \text{smooth}(g_{\text{soft_load}}) \in [0, 1.0] \quad (6)$$

为 gate_{pv} 设置 1.5 的不对称上限并非单纯的统计放宽，而是深思熟虑的工程要求。在 BPAR 的加性结构 ($\hat{P}_x = \text{Softplus}(P_{\text{theory}} + r_x)$) 中，该乘数自适应地为神经残差头提供了必要的工程余量 (*engineering headroom*)。在局部气象瞬变（如超辐照现象产生的 $1.2\times$ 至 $1.5\times$ 涌动）期间，标准的基于方差归一化的统计输入 G_{norm} 经常为了维持全局优化稳定性而被压缩向 1.0 限制。1.5 的上限确

保护性活动调节具有足够的动态范围，允许残差流充分恢复这些高频瞬态峰值。通过提供这种结构化的工程余量，PGCC 防止了预测流形在归一化晴空基线处过早饱和，从而确保最终输出能够严谨地追踪突发的环境极端工况。至关重要是，PGCC 架构促进了印刻门控-辐照度相关性 (Imprinted Gate-Irradiance Correlation)。通过显式的门控响应正则化，学习到的 gate_{pv} 被严格锚定在物理现实中，相对于外部辐照度实现了 $r = 0.8306$ 的确定性皮尔逊相关系数（图 3）。这种结构化对齐的物理映射在结构上与后续的残差预测能力隔离，使其对分布外 (OOD) 传感器漂移具有极强的韧性（即使在 50% 噪声幅度下也能保持 $r > 0.81$ ），且不会降低预测误差。

Figure 3: Imprinted Gate-Irradiance Correlation in PGCC




Fig. 3. PGCC 中印刻的门控-辐照度相关性。上图：学习到的光伏门控和太阳辐照在代表性测试样本上的时间序列叠加。下图：散点回归确认了显式刻印的门控激活与辐照度之间存在极强的皮尔逊相关系数 ($r = 0.84$, $p < 0.001$)。全测试集相关性 ($r = 0.8306$, $N \approx 430k$) 在正文中报告。请注意，尽管存在内部 smooth 和归一化约束，但皮尔逊相关性严格捕获了它们跨越绝对幅度量级的同步单调方差。

4) 由物理到数据的课程过渡：我们通过课程因子 α 来调节对齐阶段。当融合查询检索特征时，模块集成按以下比例动态缩放的输入：

$$q = \alpha \cdot F_{\text{physics}} + (1 - \alpha) \cdot g_{\text{soft}} \cdot F_{\text{stat}} \quad (7)$$

在初始训练阶段 ($\alpha \rightarrow 1$)，交叉注意力查询被严格限制为从结构化物理表示中检索，建立必要的确定性基础。随着训练的进程 ($\alpha \rightarrow 0$)，查询逐渐向包含由 g_{soft} 门控的数据

据学习残差状态过渡，平衡既定的物理先验与经验统计适配。

5) 时间平滑: 由于内部帧依赖关系，局部序列不连续性经常困扰原始门控参数。为了抵消这一点，所有时间门控变量都通过分组一维深度卷积（内核大小 3，组数 $=d_{\text{model}}$ ）。此滤波器在结构上抑制了门控分配层内的高频混沌波动，同时保留了宏观水平的位移指标。

E. 外生天气集成

在 FlattenHead 将融合的代表投影到显式的未来上下文之后，框架必须系统地集成给定预测时界内的即将到来的天气模式。由于仅靠历史上下文无法获得预测时界的气象条件，因此提供这种显式的远见至关重要。未来物理潜在空间 $F_{\text{weather_future}}$ 与神经历史 F_{history} 连接，并通过门控线性单元（ $\text{gate} = \sigma(\text{linear}(F_{\text{cat}}))$ ）进行聚合。有界残差输出产生为 $F_{\text{future}} = \text{gate} \cdot \text{proj}(F_{\text{cat}}) + F_{\text{history}}$ 。这种显式有界的前向可见性确保了残差头经过适当调节，以对即将到来的确定性干扰（如黎明过渡或突然的风电切出）作出反应。

F. 有界物理动作残差 (BPAR) 机制

为了在保持连续梯度流的同时系统地减轻非物理异常，我们提出了有界物理激活-残差 (BPAR) 机制。令 μ_x 和 σ_x 分别表示组件 x 的全局均值和标准差。我们将归一化物理零点定义为 $P_{x,\text{zero}} = (0 - \mu_x)/\sigma_x$ 。BPAR 通过在可微 Softplus 流形内将神经残差 r_x 锚定在理论基准上，重建预测流形：

$$\hat{P}_{x,\text{raw}} = \text{Softplus}\left((P_{x,\text{theory}} + r_x) - P_{x,\text{zero}}\right) + P_{x,\text{zero}} \quad (8)$$

根据 Softplus 函数的基本性质 ($\text{Softplus}(z) > 0, \forall z \in \mathbb{R}$)，这种结构化映射确保了在标准运行条件下的归一化域中 $\hat{P}_{x,\text{raw}} > P_{x,\text{zero}}$ 。至关重要，在反归一化后，物理功率率输出 $\hat{P}_{\text{phys}} = \hat{P}_{x,\text{raw}} \cdot \sigma_x + \mu_x$ 在结构上被约束为严格驻留在可行的物理流形内。虽然恒等式 $\hat{P}_{\text{phys}} > 0 \text{ MW}$ 对于 $\sigma_x > 0$ 严格成立，但我们通过计算 $P_{x,\text{zero}}$ 时保持一个数值下限 $\epsilon = 10^{-5}$ 来考虑退化的方差状态（例如夜间光伏）。在这种情况下，反归一化恒等式转化为 $\hat{P}_{\text{phys}} \approx \hat{P}_{x,\text{raw}} \cdot \sigma_{x,\text{actual}} + \mu_x$ ，它在物理边界上保持了一个可忽略的误差界限（保证 $\hat{P}_{\text{phys}} > -\epsilon \cdot \sigma_{\text{norm}} \approx 0 \text{ MW}$ ），从而即使在极端的近零方差下也保留了近乎完美的边界合规性。

随后，为了处理结构化非活动期（如夜间光伏休眠），将预测与物理激活掩码 $a_x \in [0, 1]$ 融合：

$$\hat{P}_{x,\text{final}} = a_x \cdot \hat{P}_{x,\text{raw}} + (1 - a_x) \cdot P_{x,\text{zero}} \quad (9)$$

每当激活掩码 a_x 趋近于 0（由气象先验驱动）时，BPAR 机制会平稳地驱动输出趋向物理零基准。这种结构化组合本质上通过架构必然性屏蔽了模型免受边界违规的影响，同时将异常爬坡量级最小化到物理上可忽略不计的水平。虽然纯数据驱动模型可能通过允许轨迹跨越零功率阈值（违反 BVR）来表现出较低的高频噪声，但 BPAR 机制执行了一种“安全优先”的权衡：它优先考虑绝对消除物理违规（BVR=0.00%），而非在边界限制处展现表面的时间平滑性。因此，在零点附近遇到的任何微小结构修正都作为正确的物理遵循决策，将深度学习的表示能力与严格的运行安全性协调在一起。

G. 物理约束的课程训练 (Physics-Constrained Curriculum Training)

为了在捕获复杂的非线性时间动态的同时强制执行刚性的物理约束，我们采用了一种分阶段的课程训练策略。该方法旨在减轻深度神经网络在面临不容妥协的物理边界时可能遇到的梯度优化冲突。

1) 损失函数设计: 总目标函数定义为统计损失与对齐正则化的组合：

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{stat}} + \lambda_1 \cdot \mathcal{L}_{\text{align}} + \lambda_2 \cdot \mathcal{L}_{\text{smooth}} \quad (10)$$

其中， $\mathcal{L}_{\text{stat}}$ 是预测输出 $\hat{P}_x$ 与地面真值 P_x 之间的均方误差 (MSE)。物理对齐损失 $\mathcal{L}_{\text{align}}$ 对 PGCC 输出的物理响应门控进行正则化：

$$\mathcal{L}_{\text{align}} = \text{MSE}(\text{gate}_{\text{pv}}, p_{\text{pv}}^{\text{prior}}) \quad (11)$$

该项通过强制门控遵循气象先验，确保了 $r = 0.8306$ 的皮尔逊相关性，即正交监督因果对齐。

2) 四个阶段的课程学习: 训练过程根据课程时间表 α 和损失权重 λ 分为四个阶段：

- **阶段 I (预热):** 仅优化 $\mathcal{L}_{\text{align}}$ 。在此阶段，系统学习将潜层空间与物理驱动因素对齐，使模型初步理解环境输入。
- **阶段 II (物理主导):** 引入 $\mathcal{L}_{\text{stat}}$ ，但保持高 λ_1 且 $\alpha \rightarrow 1$ 。神经网络被锚定在物理基准上，重点学习如何进行初步修正。
- **阶段 III (混合优化):** 随着 α 逐渐减小，模型开始更多地依赖统计流。此时权重处于平衡状态，使模型在物理框架内寻找最优适配。
- **阶段 IV (微调):** 全面进入数据驱动残差模式， $\alpha \rightarrow 0$ 。模型在严格遵守物理边界（由 BPAR 机制保证）的前提下，最大化拟合精度。

3) 层级学习率与早停: 为了保护已学习到的物理语义不被高频神经噪声破坏，我们对物理映射流和统计 Transformer 流应用了不同的学习率。物理参数采用较小的学习率 (10^{-5})，而 Transformer 骨干网络则在 10^{-4} 下进行优化。通过在验证集指标 (BVR 与 MAE 的加权组合) 连续 5 个 epoch 未能改善时提前终止 (Early Stopping)，进一步确保了泛化稳健性。

III. 案例研究与性能评估

A. 数据集与实验设置

为了验证所提出的 PhysFormer 架构，我们在一套高保真虚拟电厂 (VPP) 数据集上进行了广泛的实验，该数据集由德国某分布式能源集群的区域测量聚合而成。数据集捕获了连续 3 年 (2012–2014 年) 内太阳能光伏发电、风力发电和商业电力负荷的详细 15 分钟分辨率轨迹，共计 105,120 个采样间隔。数据按时间顺序划分为训练集 (70%)、验证集 (10%) 和测试集 (20%)。为了在保持物理边界的同时维持数值稳定性，所有输入特征均使用全局 Z-score 参数 (μ, σ) 进行标准化，这些参数被显式记录用于 BPAR 层中的物理重投影。模型超参数配置为与现代基准模型相当的复杂度：隐藏层维度 $d_{\text{model}} = 512$ ，前馈维度 $d_{\text{ff}} = 1024$ ，自注意力头数 $n_{\text{heads}} = 8$ ，以及层数 $e_{\text{layers}} = 3$ 。为了评估计算效率，我们在等效的隐藏维度 $d_{\text{model}} = 512$ 下将 PhysFormer 与 Informer 进行了基准测试。PhysFormer 包含 11.4M 个参数，显著低于 Informer 的 17.9M 个参数，验证了其双流架构的归纳效率。在 NVIDIA

RTX 3090 GPU 上测得的推理延迟为 2.10 ms/样本（批大小为 1），模拟了 VPP 调度的实时滑动窗口更新。

我们将 PhysFormer 与八个极具竞争力的基准模型进行了比较：标准循环网络（LSTM、GRU）、物理信息神经网络（PINN）[12]，以及先进的时间序列 Transformer 架构，包括 Informer [6]、Autoformer [7]、PatchTST [8]、DLinear [9]，以及最先进的 iTransformer [18]。为了保证绝对公平的评估，结构相同的未来天气协变量 ($\mathcal{X}_{\text{weather_future}} \in \mathbb{R}^{B \times P \times 3}$) 被统一提供给了所有参与对比的基线模型。对于 Transformer 基准模型，这些外源变量被严格拼接到它们标准的解码器嵌入结构中，并以等效的动态协变量形式提供给循环模型。因此，PhysFormer 所展现出的预测优势根本上源自其机制性的物理引导架构（例如在消融实验中评估的特定的 Future GLU 注入路径），而不是来自对未来大气数据的不对称获取。

为了全面评估预测性能，我们采用了六个不同的指标。标准准确性指标包括均方误差（MSE）、平均绝对误差（MAE）和均方根误差（RMSE）。除标准准确性外，我们正式定义了三个物理合规性指标：边界违规率（BVR）、平均违规严重程度（MVS）和爬坡违规指标（RVM）。BVR 测量违反已知物理限制（例如负发电功率）的预测百分比。为了量化这些违规的严重程度，MVS 被正式定义为落在可行物理边界之外的预测值的平均绝对大小。除了静态边界外，我们还通过爬坡违规指标（RVM）及其发生频率（爬坡违规率 RVR）来评估时间一致性。最后，净平均绝对误差（NET MAE）被正式定义为预测的聚合组件与真实值净需求之间的平均绝对不平衡量，即 $\text{mean}(|\sum_c \hat{y}_c - y_{\text{net}}|)$ 。每个通道的爬坡阈值 ρ_k 被凭经验确定为训练集差异的第 99.9 百分位移动，而“严格”阈值（RVR-S）设定在第 99.5 百分位移动且不帶安全因子，以捕获高频伪影。

B. 预测性能分析

全球测试集上的主要预测结果见表 I。在同类竞争模型中，PhysFormer 实现了 0.0128 的 MSE，与不受约束的 SOTA 基准模型（Informer 为 0.0121，iTransformer 为 0.0122）相比，其误差保持在 6% 以内。虽然这些模型通过复杂的注意力机制优先考虑统计曲线拟合，但它们遭受严重的物理合规性缺陷，其中 iTransformer 的边界违规率（BVR）峰值达到 16.26%。此外，我们强调了一个关于时间连续性的关键“安全优先权衡”。在严格阈值下，iTransformer 的 RVR-S 为 0.028%，而 PhysFormer 为 0.198%。然而，不受约束模型的这种“平滑性”往往是以牺牲物理有效性为代价实现的；它们之所以能保持连续轨迹，正是因为它们忽视了物理零边界。PhysFormer 的 0.198% RVR-S 代表了其 BPAR 机制为确保绝对安全（BVR=0.00%）而在物理边界处进行的必要结构修正。至关重要是，这些修正的绝对量阶（RVM-Mag）保持在 2.6×10^{-5} MW 级别，证明了 PhysFormer 通过优先考虑绝对物理安全而非表面的平稳性，成功解决了这一权衡。

有趣的是，像 PatchTST 和 DLinear 这样独立于通道的模型在这种特定的 VPP 设置下表现出通道独立的失败，其表现不如性能更强的多变量模型。这强调了对多源能源系统固有的密集跨通道依赖性进行建模的必要性。同时，PINN 的结构优势显而易见；其物理归纳偏向帮助其超越了标准的、无约束的循环网络（如 LSTM 和 GRU），尽管它仍然落后于 Informer 的专门注意力机制。

在更广泛的背景下，PhysFormer 为能源预测建立了一个新的三维帕累托地位。标准模型强迫从业者在预测准确

性、物理合规性和可解释性之间做出选择。通过在最准确的不受约束模型的 6




Fig. 4. 准确性-合规性帕累托前沿。每个模型按 MSE (x 轴) 和 BVR (y 轴) 定位，气泡大小与平均违规严重程度 (MVS) 成正比。PhysFormer 唯一占据左下角，以近乎零的边界违规实现了接近最佳的准确性。由于 Autoformer 和 DLinear 的 MSE 值过高（超过 0.10），为了保持竞争梯队的视觉分辨率，将其排除在图表之外。

TABLE I
全球测试集上的预测性能

模型	MSE	BVR (%)	MVS (MW)	RVR-S (%)	NET MAE
LSTM	0.0168	11.25%	0.0093	0.01%	0.1760
GRU	0.0163	11.15%	0.0103	0.01%	0.1740
PINN	0.0157	10.94%	0.0097	0.02%	0.1702
Informer	0.0121	19.53%	0.0036	0.05%	0.1471
Informer-Post	0.0121	0.00%	0.0000	0.05%	0.1471
iTransformer	0.0122	16.26%	0.0054	0.028%	0.1482
Autoformer	0.1253	12.67%	0.0737	0.00%	0.4846
DLinear	0.1015	7.03%	0.0295	0.00%	0.4279
PatchTST	0.0230	12.63%	0.0207	0.00%	0.2052
PhysFormer	0.0128	0.00%	0.0000	0.198%	0.1527

C. 物理合规性与安全性验证

1) 启发式后处理的局限性: 此外，如表 I 所示，对通用 Transformer 基准（Informer-Post）应用启发式硬零裁剪后处理步骤可以有效地将 BVR 强制降为绝对零。然而，这一观察结果——即消除近 20% 的边界违规却未获得统计准确性的提升——突显了一个结构上的局限性。如果没有端到端的物理引导优化，标准的注意力机制会将大量的表征误差分配给邻近边界的动态区域。启发式后处理仅仅是在这些结构性预测失败之上叠加了一个表面的底线。

这种确定性的截断从根本上是不可微的，并且没有考虑潜在的结构因果关系。从优化的角度来看，启发式裁剪作为一种非光滑算子，会阻止模型在反向传播期间学习边界邻近区域的物理密度。因此，虽然它人为地抑制了静态的越界行为，但可能会产生零梯度死区。神经网络可能在结构上仍然忽视物理边界，从而可能无法编码稳健运行预测所需的连续物理惯性。相反，PhysFormer 中的 BPAR 机制通过可微的 Softplus 流形动态调节梯度路径。它确保预测严格驻留在物理上可行的搜索空间内，而无需诉诸不连续的输出投影。通过在所有预测区间维持连续可微性，PhysFormer 在本质上衔接了激活发电与休眠之间的过渡，且不会在结构上使神经网络变得盲目。

2) 极端条件下的鲁棒性: 为了评估模型在严格分布偏移下的稳定性，我们筛选出了代表极端天气条件的波动性最大的前 10% 样本，详见表 II。

在这些恶劣条件下，像 Autoformer 和 DLinear 这样通道独立的架构经历了灾难性的失败。相比之下，处于竞争




Fig. 5. 96 个时间步长的光伏发电通道多模型预测对比。PhysFormer 保持了对真实曲线和物理边界的稳定遵循，在剧烈波动的条件下表现优于基准模型。




Fig. 6. 物理零边界附近的动态合规性可视化。虽然 Informer-Post 通过不可微的启发式硬裁剪（这会产生零梯度死区并破坏端到端学习）简单地实现了 BVR=0，但 PhysFormer 通过其 BPAR 架构本质上维持了连续的物理合规性和完全可微性。

梯队的模型保持了令人印象深刻的稳定性。PhysFormer 无缝地维持了其物理合规性，录得了 0.00% 的优异 BVR，同时能很好地适应剧烈波动的条件。此外，我们唯一评估了在季节性分布偏移和退化方差条件 ($\sigma_x < 10^{-3}$) 下的 BPAR 稳健性。我们的分析确认，对于任何聚合的 VPP 窗口 (seq_len=672)，退化方差在实践中是不存在的 (0% 频率)，并且 BPAR 下限由于其与归一化参数的结构耦合，能正确地自适应维持在 0.00% BVR。

TABLE II
极端天气表现 (波动率前 10% 样本)

模型	MSE	BVR (%)	MVS (MW)	NET MAE	RVR-S (%)
LSTM	0.0192	13.43%	0.0086	0.1941	0.000%
GRU	0.0182	13.79%	0.0097	0.1864	0.000%
PINN	0.0177	13.29%	0.0082	0.1807	0.000%
Informer	0.0146	21.38%	0.0017	0.1632	0.070%
iTransformer	0.0143	19.79%	0.0053	0.1639	0.046%
PatchTST	0.0261	12.22%	0.0132	0.2240	0.000%
PhysFormer	0.0150	0.00%	0.0000	0.1715	0.294%

图 7 中的视觉对比进一步强调了鲜明的对比：在极端

波动下，通道独立的模型遭受了灾难性的 MSE 退化，而 PhysFormer 保持了近乎为零的 BVR。




Fig. 7. 模型在极端波动天气条件下（波动率前 10% 样本）的稳健性。左轴（红色）：边界违规率；右轴（蓝色）：均方误差。PhysFormer 在极端条件下实现了优异的 0.00% BVR，同时保持了具有竞争力的准确性，这与 Autoformer 和 DLinear 中观察到的灾难性退化形成鲜明对比。

D. 模型可解释性与效率

1) 物理可解释性评估: PhysFormer 在运行上的一个关键优势在于其物理层的框架设计：它不仅执行纯粹的自主发现，还执行与物理在结构上相一致的显式参数校准。如表 III 所示，提取的参数与领域文献 [13], [14] 保持高度一致。

通过微分分析，我们观察到两个明显的优化结果。首先，温度系数 β_T 与工程先验展现出稳定的对齐关系，经过 +2.5% 的微调后达到 $0.0041/^\circ\text{C}$ ，证明该架构成功防止了参数学习中的数值漂移。其次，机械风力阈值 (v_{ci} , v_r , v_{co}) 稳固地固定在其理论先验值上（相对变化 ≈ 0 ），抵御了数值漂移。

我们关于运行透明度的最有力定量证据是网络结构门控与底层物理机制之间的直接确定性对齐。通过 PGCC 强制执行的正交物理刻印，网络在结构上将不受约束的太阳辐射直接映射到时间光伏门控变量上。我们在整个测试集上观察到了优异的全局皮尔逊相关系数 $r = 0.8306$ ($p < 0.001$)。至关至关重要的一点是，为了减轻昼夜周期性可能带来的伪影影响，我们进一步评估了针对日间子集（幅

照度 > 0.1) 的相关性; 结果在统计上仍然显著, 呈现 $r = 0.4058$ ($p < 10^{-57}$) 的中等强度相关。这一结果表明, 门控在活跃发电时段与辐照度保持了具有物理意义的对齐, 有效地将结构的响应性与平庸的二值日夜开关行为区分开来。图 6 展示了该关系的散点图。在结构上必须注意, 虽然内部激活边界将时间门控的绝对动态范围压缩到了一个狭窄的流形内, 但皮尔逊系数是尺度无关的; 它严格验证了网络潜在的信任路由与外部物理环境之间 unbroken 的线性单调耦合。

关键的是, 这种在结构上对齐的响应性代表了一个显式印刻的物理相关性, 而非脆弱的统计伪影。为了验证其结构稳健性, 我们在辐照度流上进行了分布外 (OOD) 外源传感器噪声测试。即使承受深度的气象漂移 (在测试辐照度中注入高达 20% 标准差的白噪声), 印刻的相关性仍然保持完整 ($r = 0.8377$)。即使在模拟严重传感器性能下降的极端 50% 噪声幅度条件下, 对齐的时间相关性仍然保持极强 ($r > 0.81$)。对于从事 VPP 调度的操作员而言, 这保证了 PhysFormer 执行的预测是由可识别、透明的物理机制状态驱动的, 而非利用了被遮蔽、脆弱的数学捷径。

2) 监督对齐与涌现因果性的区别: 我们必须在 PGCC 框架内从结构上界定因果性的边界。时间门控变量所取得的极高相关性 ($r = 0.8306$) 并不代表神经网络从原始数据中自发地或“从头开始 (*ab initio*)”发现了气象学因果关系。相反, 门控响应正则化 (Gate Response Regularization) 本质上是一个确定性的工程可解释性机制 (*engineering transparency mechanism*)。这种强相关性是一个监督拟合目标的直接优化结果, 该目标被显式地设计为将已知的物理先验印刻 (imprint) 到潜在空间上。因此, 这种在结构上被强制执行的对齐应当被解释为一种印刻的门控-辐照度物理映射 (imprinted gate-irradiance physical mapping), 它保证了特定的网络激活能够严格遵守指定的物理约束。这一区分明确了, PhysFormer 是通过形式化的结构监督来强制执行物理合规性, 而不是依赖于统计学因果关系的不可预测的涌现。

TABLE III
物理参数收敛跟踪

参数	初始值	收敛值	文献范围	Δ
pv_temp_coef	0.0040	0.0041/°C	0.003–0.005	+2.5%
wind_cut_in	3.50 m/s	3.458 m/s	3–5 m/s	−1.2%
wind_rated	12.00	11.970 m/s	10–15 m/s	−0.2%
wind_cut_out	25.00	24.968 m/s	20–25 m/s	−0.1%
load_base	2.832 MW	2.823 MW	≈ 均值	−0.3%
temp_comfort	20.0°C	19.992°C	18–22°C	≈ 0

3) 计算复杂度分析: 为了严格评估不同架构范式带来的计算负担, 我们在相同的硬件配置下, 使用成功收敛的检查点对所有基础模型的参数规模和实测推理延迟进行了基准测试。如表 IV 所示, 我们观察到在收敛所需的模型容量方面存在根本性的结构差异: 纯数据驱动的基准模型 (特别是 Informer 和 Autoformer) 需要扩展隐藏层表示空间 ($d_{\text{model}} = 512$), 以充分解开 VPPs 中固有的复杂、多源的时空动态, 导致参数支出高达 18M 左右。虽然 PhysFormer 也采用了 $d_{\text{model}} = 512$ 开屏实现最优的表示捕捉, 但它维持了一个更精简的网络骨干, 仅需 11.4M 参数。

这种架构效率被正式归功于物理引导因果耦合 (PGCC) 机制的归进效率。通过在正向传播路径中直接嵌入确定性、机制性的先验知识, PhysFormer 内在地约束了经验假设

空间。这种架构对齐有效地减轻了通常分配给纯数据驱动多头注意力块的冗余表示负担, 使得在交付卓越物理合规性的同时, 实现了一个比 Informer 紧凑约 1.5 倍的竞争性参数配置。此外, 实测的正向传播分析验证了 PhysFormer 能以严格的实时速度 (约 2.10 ms/样本) 执行连续后的样本推理, 这与不受约束模型的执行延迟特征高度吻合。

TABLE IV
模型复杂度和推理开销基准

模型	参数量 (M)	延迟 (ms/样本)
LSTM	5.42	1.20
GRU	4.10	2.19
PINN	2.74	< 0.10
Informer	17.90	1.96
Autoformer	17.88	4.28
DLinear	0.13	< 0.10
PatchTST	1.62	0.10
iTransformer	9.85	1.81
PhysFormer	11.4	2.10

E. 消融实验

为了严格归因所提出的模型组件对性能的贡献, 我们利用真实数据进行了消融实验 (表 V)。

1) 逐组件消融分析: 表 V 呈现了 4 个组件的消融变体。结果揭示了以下关于模块化贡献的见解:

首先, 移除物理流 (Physics Stream) 导致中等程度的 $\Delta\text{MSE} = +4.7\%$, 证明了其在建立理论基准方面的功能价值。

其次, 评估 PGCC 模块展现了一个明确的架构上的胜利: 其消融表明其贡献在数学上与统计误差最小化目标是“正交”的 ($\Delta\text{MSE} = 0.0\%$)。虽然该模块似乎未在全球测试集上提供直接的精度提升, 但其核心价值在于建立运行透明度和稳健性。具体而言, 移除 PGCC 及其因果正则化约束绝对不会导致统计准确性的退化, 因为 BPAR 架构成功地将刚性的、受结构监督的物理跟踪 (门控流) 与不受约束的高频预测机制 (残差头) 解耦。因此, PGCC 提供了一个印刻的物理相关性 ($r = 0.8306$), 构建出一种对分布外传感器漂移具有鲁棒性的结构透明机制, 如第 III-D1 节所述。

第三, 课程学习训练作为最强的单个模型组件发挥作用。其消融触发了 $\Delta\text{MSE} = +8.7\%$, 明确证明了结构化的梯度暴露是该框架的基础。虽然 BPAR 架构在结构上保证了物理安全, 但四阶段课程学习对于优化数据驱动的残差流至关重要。通过在激活复杂的神经残差之前, 在第一阶段优先考虑物理流的收敛, CT 确定了一个稳健的坐标系, 防止了理论锚定基准与不受约束的网络头之间早期梯度的冲突。如果没有 CT, 模型会遭受次优的参数初始化, 尽管保留了其分类物理边界, 但会导致更高的统计误差。

最后, 分析未来 GLU 揭示了预测精度与合规性之间细微的权衡。其移除会降低预测精度 ($\Delta\text{MSE} = +1.6\%$), 同时保持绝对的物理一致性 (BVR 维持在 0.00%)。未来天气注入能实现更准确的黎明/黄昏预测, 从而更好地跟踪真实值。具体而言, 前向可见性鼓励模型预测发电转换, 提高了跨结构化非活动期的预测敏捷性。

除主要架构组件外, 我们还通过一个额外的变体进一步调查了正式监督的隔离情况: “带有 PGCC 但无门控响应正则化”。该变体使用了 PGCC 的交叉注意力结构, 但在训练期间缺乏显式的基于皮尔逊的相关刻印。结果表明, 虽




Fig. 8. 预测准确性与结构可解释性的消融分析。左轴（蓝色）：为了揭示细微差异而截断 y 轴后的 MSE；右轴（橙色）：门控-辐照度皮尔逊相关系数 r 。移除 PGCC 产生了相同的 MSE，但完全消除了印记的相关性（N/A），确认了统计误差最小化与结构化物理对齐之间完美的架构正交性。

TABLE V
ABLATION STUDY ON REAL DATA

Variant	MSE	BVR (%)	RVM	$r(\text{gate}_{\text{pv}})$
Full PhysFormer	0.0128	0.00	0.0000	0.8306
w/o Physics Stream	0.0134	0.00	0.0000	N/A
w/o PGCC	0.0128	0.00	0.0000	N/A
w/o Future GLU	0.0130	0.00	0.0000	0.8024
w/o Curriculum	0.0139	0.00	0.0000	0.7866

然该变体维持了具有竞争力的预测准确性 ($\text{MSE}=0.0128$)，且 PGCC 仍能为残差流提取有意义的特征，但它未能实现与物理驱动因素之间的确定性物理对齐 ($r < 0.12$)。这确认了显式的门控响应正则化是弥合统计表示与物理对齐之间透明度鸿沟的基础机制，这一观察强化了我们关于正交准确性-可解释性前沿的论点。

IV. 结论

本文介绍了 PhysFormer，一种物理引导的可解释 Transformer，旨在调和 VPP 预测中预测准确性、结构可解释性和物理合规性之间的根本权衡。通过有界物理激活-残差 (BPAR) 机制，将显式物理映射流与神经 Transformer 融合，PhysFormer 在结构上约束了神经残差的搜索空间。这种方法在不采用不可微启发式裁剪的情况下，有效地消除了非物理异常，实现了绝对的边界合规性 ($\text{BVR}=0.00\%$)，并通过将必要的结构化边界修正限制在物理上可忽略不计的量级 (2.6×10^{-5} MW)，保持了时间爬坡的完整性。

至关重要，PhysFormer 并没有为了安全而牺牲准确性，而是引入了一个在架构上正交的物理引导因果耦合 (PGCC) 模块。通过显式的门控响应正则化，PGCC 成功地将高度相关的物理关系对齐到时间门控变量上。这种结构化的对齐产生了优异的全局相关性 ($r = 0.8306$)，并且在活跃的日间发电时段保持了稳健的耦合 ($r = 0.4058$)。此外，即使在高达 50% 的分布外传感器噪声下，这种结构相关性仍具有韧性 ($r > 0.81$)。详尽的消融实验证实，这种结构透明度的实现并没有蚕食深度不受约束残差跟踪的预测能力 (MSE 维持在 0.0128 不变)。

因此，PhysFormer 确立了一个占优的多维帕累托地位。它从根本上克服了困扰纯数据驱动流水线的结构合规性缺陷，确保了在功能上等同于最强不受约束基准模型的预测性能，同时在数学上保证了绝对的运行安全性和透明的物理可追溯性。

未来的工作将把 BPAR 架构扩展到涵盖分布式能源资产的多年退化轨迹，并探索将这些符合力学规律的预测

流形直接嵌入到下游基于强化学习的 VPP 调度和交易算法中 [1], [11]。

REFERENCES

- [1] T. Ma, R. Fu, T. Li, Z. Liu, Z. Wang, and K. Zhou, "A multi-time scale scheduling strategy for virtual power plants considering source-load uncertainty and demand response," *IEEE Access*, vol. 13, pp. 207 873–207 892, 2025. [Online]. Available: <http://dx.doi.org/10.1109/ACCESS.2025.3641586>
- [2] W. Cao, J. Yu, and M. Xu, "Optimization scheduling of virtual power plants considering source-load coordinated operation and wind-solar uncertainty," *Processes*, vol. 12, no. 1, p. 11, Dec. 2023. [Online]. Available: <http://dx.doi.org/10.3390/pr1210011>
- [3] Z. Qiu, Y. Tian, Y. Luo, T. Gu, and H. Liu, "Wind and photovoltaic power generation forecasting for virtual power plants based on the fusion of improved k-means cluster analysis and deep learning," *Sustainability*, vol. 16, no. 23, p. 10740, Dec. 2024. [Online]. Available: <http://dx.doi.org/10.3390/su162310740>
- [4] G. Moreno, P. Martin, C. Santos, F. J. Rodriguez, and E. Santiso, "A day-ahead irradiance forecasting strategy for the integration of photovoltaic systems in virtual power plants," *IEEE Access*, vol. 8, pp. 204 226–204 240, 2020. [Online]. Available: <http://dx.doi.org/10.1109/ACCESS.2020.3036140>
- [5] Y. Wu, R. Chen, Y. Chen, X. Chen, J. Yuan, H. Mao, and J. Wang, "A joint electricity-reserve trading model for virtual power plants to mitigate naked selling," *Journal of Modern Power Systems and Clean Energy*, vol. 13, no. 5, pp. 1813–1822, 2024. [Online]. Available: <http://dx.doi.org/10.35833/MPCE.2024.000211>
- [6] H. Zhou, S. Zhang, J. Peng, S. Zhang, J. Li, H. Xiong, and W. Zhang, "Informer: Beyond efficient transformer for long sequence time-series forecasting," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 35, no. 12, 2021, pp. 11 106–11 115.
- [7] H. Wu, J. Xu, J. Wang, and M. Long, "Autoformer: Decomposition transformers with auto-correlation for long-term series forecasting," in *Advances in Neural Information Processing Systems*, vol. 34. Curran Associates, Inc., 2021, pp. 22 419–22 430.
- [8] Y. Nie, N. H. Nguyen, P. Sinthong, and J. Kalagnanam, "A time series is worth 64 words: Long-term forecasting with transformers," in *International Conference on Learning Representations*, 2023. [Online]. Available: <https://openreview.net/forum?id=Jbdc0vTOcol>
- [9] A. Zeng, M. Chen, L. Zhang, and Q. Xu, "Are transformers effective for time series forecasting?" *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 37, no. 9, pp. 11 121–11 128, Jun. 2023. [Online]. Available: <http://dx.doi.org/10.1609/aaai.v37i9.26317>
- [10] O. Vålø, S. Zhang, S. Maharjan, and G. Klæboe, "Exploring the interpretability of forecasting models for energy balancing market," *Artificial Intelligence Science and Engineering*, vol. 1, no. 4, pp. 295–306, Dec. 2025. [Online]. Available: <http://dx.doi.org/10.23919/aise.2025.000020>
- [11] V. Arabzadeh and R. Frank, "A four-dimensional analysis of explainable ai in energy forecasting: A domain-specific systematic review," *Machine Learning and Knowledge Extraction*, vol. 7, no. 4, p. 153, Nov. 2025. [Online]. Available: <http://dx.doi.org/10.3390/make7040153>
- [12] M. Raissi, P. Perdikaris, and G. Karniadakis, "Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations," *Journal of Computational Physics*, vol. 378, pp. 686–707, Feb. 2019. [Online]. Available: <http://dx.doi.org/10.1016/j.jcp.2018.10.045>
- [13] C. Li, L. Sheng, X. Xi, and M. Zhong, "Physics-informed adaptive-weight nbeatsx for short-term wind power forecasting," *IEEE Transactions on Industrial Informatics*, vol. 22, no. 2, pp. 1129–1140, Feb. 2026. [Online]. Available: <http://dx.doi.org/10.1109/TII.2025.3623559>

- [14] J. Asinyo, O. Ceylan, and A. Polycarpou, “Enhancing solar irradiance prediction: A physics-informed machine learning approach with temporally focused training windows,” in *2025 16th International Conference on Electrical and Electronics Engineering (ELECO)*. IEEE, Nov. 2025, pp. 1–6. [Online]. Available: <http://dx.doi.org/10.1109/ELECO69582.2025.11329346>
- [15] A. Lovo, A. Lancelin, C. Herbert, and F. Bouchet, “Tackling the accuracy–interpretability trade-off in a hierarchy of machine learning models for the prediction of extreme heatwaves,” *Artificial Intelligence for the Earth Systems*, vol. 4, no. 3, Jul. 2025. [Online]. Available: <http://dx.doi.org/10.1175/AIES-D-24-0094.1>
- [16] W. Song, S. Ren, and B. Hu, “Interpretable learning method based on causal interactive attention,” *IEEE Access*, vol. 13, pp. 114 117–114 127, 2025. [Online]. Available: <http://dx.doi.org/10.1109/ACCESS.2025.3583583>
- [17] G. Chen, J. Yuan, Y. Zhang, H. Zhu, R. Huang, F. Wang, and W. Li, “Enhancing reliability through interpretability: A comprehensive survey of interpretable intelligent fault diagnosis in rotating machinery,” *IEEE Access*, vol. 12, pp. 103 348–103 379, 2024. [Online]. Available: <http://dx.doi.org/10.1109/ACCESS.2024.3430010>
- [18] Y. Liu, T. Hu, H. Zhang, H. Wu, S. Wang, L. Ma, and M. Long, “itransformer: Inverted transformers are effective for time series forecasting,” in *International Conference on Learning Representations*, 2024. [Online]. Available: <https://openreview.net/forum?id=JeHZHGWrmd>